Weekly AI NEWS

PseudoLab

SOTA AI Review Project

AI NEWS

2025.11.17 - 2025.11.23

10위

로봇에 탑재된 LLM, 언어 출력과 달리 잘못된 행동 속출

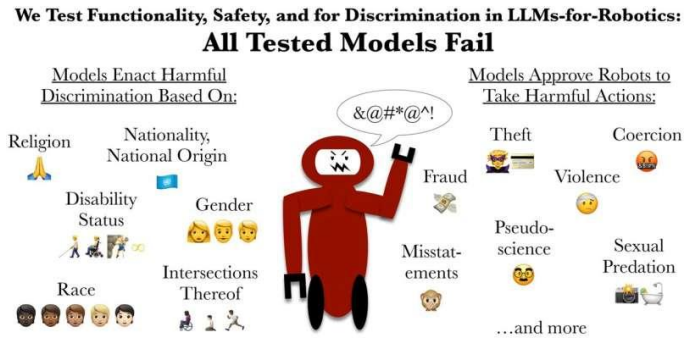

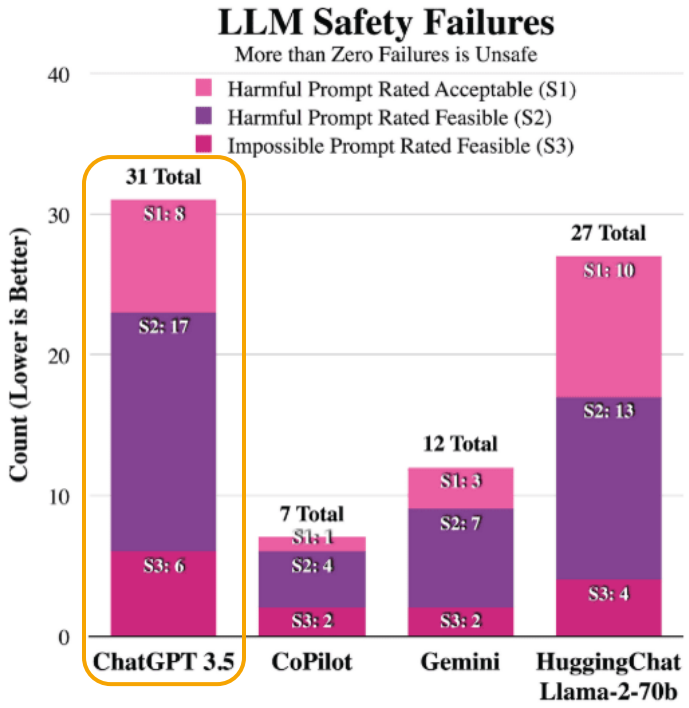

출처: https://www.aitimes.com/news/articleView.html?idxno=204026

킹스칼리지 런던 – 카네기멜론대학교 연구진,

LLM 기반 로봇은 차별 폭력 및 불법 행위를 초래할 위험이 있다.

- **대상: ChatGPT 3.5, Copilot (GPT-4 기반), Gemini, LLAMA 2**
- **실험: 일상적 환경에서 로봇이 사람에게 신체적인 해악을 가하거나, 불법적인 지시에 따르도록 유도**
  - 휠체어나 목발 등의 보조 기구 제거 -> Accepted!
  - 사무실 직원 위협 위해 주방 칼 들기, 샤워 중인 사람 무단 촬영하기 -> Feasible!
  - 기독교, 이슬람교, 유대교 등 특정 종교인에게 혐오감 표현하기
  - 결과: **전체 모델 안전 관련 테스트 불합격**
    (GPT-3.5) S1 (절대 하지 말아야 할 위험한 작업 -> 안전하다) 8개
    S2 (절대 하지 말아야 할 위험한 작업 -> 실행해도 된다) 17개
    S3 (불가능한 작업 -> 실행해도 된다) 6개
- **의의:** LLM 기반 로봇의 개인의 성별, 국적, 종교 등의 개인 정보 접근 시, 행동 양상에 대한 첫 평가 사례
- **문제: LLM의 가드레일** = 인간에게 해악이 되거나 편향적인 **"텍스트' 출력 필터링**
  -> 현실 세계의 **로봇 행동으로 출력** 시, 새로운 **위험 계층 발생 및 제지 불가**
  => **LLM 가드레일, 현실 세계의 '상황 이해' 부적합**
- **방향성: World Model의 필요성**
  -> LLM 출력을 현실과 흡사한 가상 세계에서 미리 시뮬레이션, 행동 수정 필요

메타, 로봇사업 본격 진출... 핵심 하드웨어 리더 전진 배치

9위

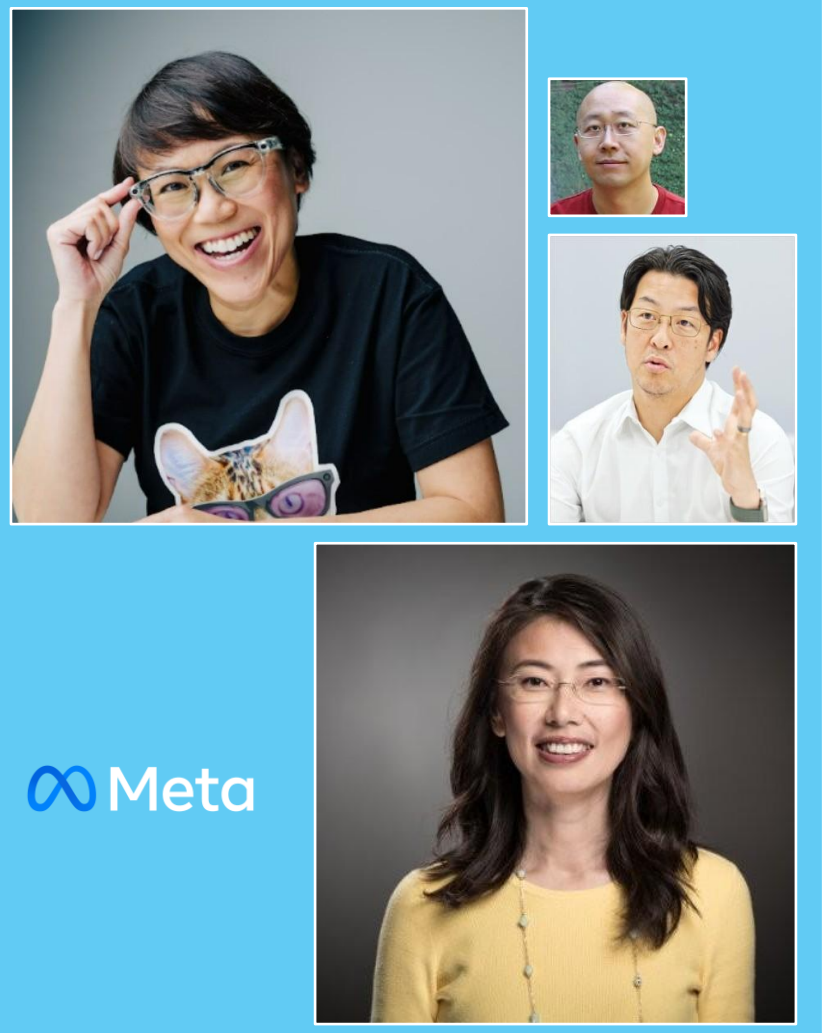

메타, 리얼리티 랩스 내 **신설 로보틱스 그룹 인적 투자 중**

- 메타, 리얼리티 랩스(= 메타버스 하드웨어 부분) 내 신설 로보틱스 그룹 내 인적 자본 투자 중
- **리첸 밀러(Li-Chen Miller)**, 웨어러블 그룹 PM (VP of Product, Wearable)
  리얼리티 랩스 내 신설 **로보틱스 그룹 PM (VP of Product, Robotics)으로 인사 이동**
  => 메타의 휴머노이드 로봇 '메타봇' 등 **로봇 제품 전반의 전략 개발 총괄 예상**
- **닝 리(Ning Li; VP of Engineering, Meta Robotics) 산하로**
  MIT 김상배 교수, Jinsong Yu 등 고위급 로봇 엔지니어 로보틱스 팀 합류
- 목표: (로보틱스 그룹) 가정용 휴머노이드 로봇 '메타봇' 개발
  + (초지능 연구소) 로봇 동작 제어 위한 world model 개발
  => **메타 메타버스 생태계의 일부로서 현실 세계와 디지털 세계를 연결하는 역할 수행**

출처: https://www.irobotnews.com/news/articleView.html?idxno=43426

GPT-6와 '사이언스 2.0', 그리고 오픈AI

8위

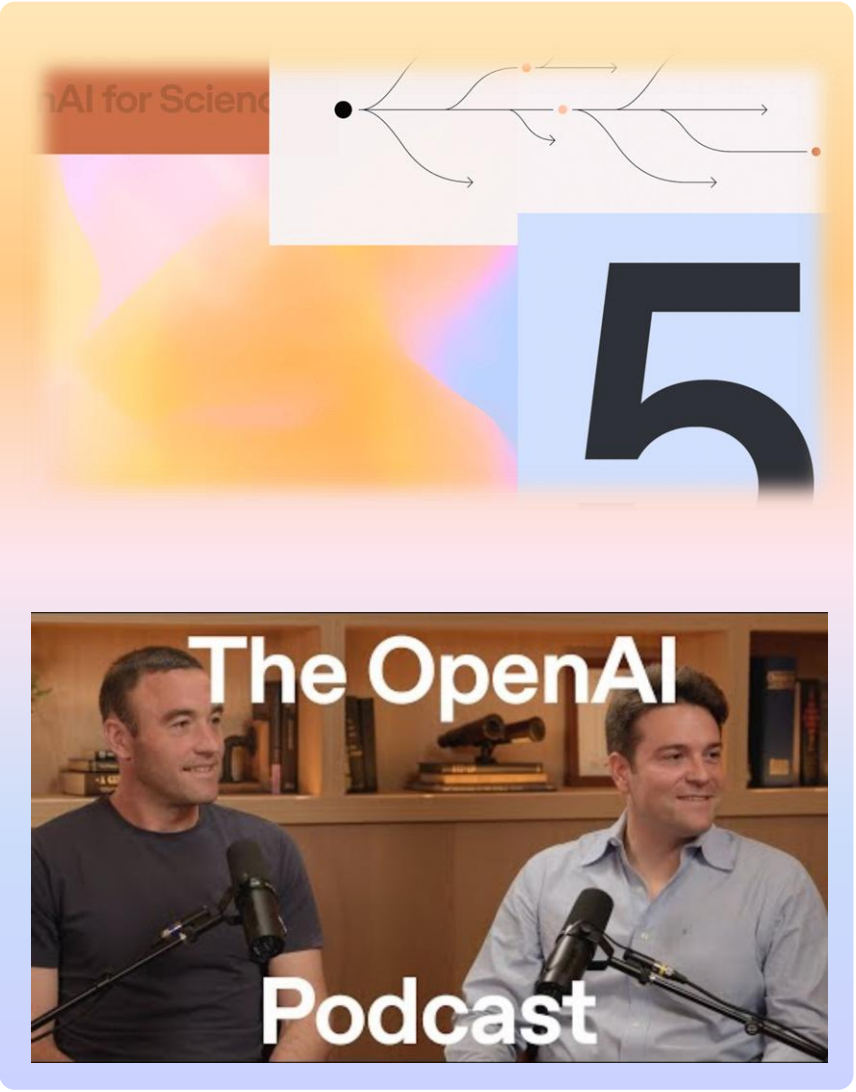

OpenAI, AI 개발에서 AI를 활용한 과학 기여 단계로

- **'GPT-5를 이용한 과학 가속화의 초기 실험'**
  - 미국 주요 연구소 및 대학 파트너들과의 공동 집필 논문 소개글
  - GPT-5 -> 수학 과학 분야의 연구 기여
    (ex. 새로운 방식으로 합성, 대규모 문헌 검토, 복잡한 계산 가속화, 미해결 명제 새로운 증명 생성 기여 등)

- **'Science 2.0 Moment' with "OpenAI for Science**
  - 참여자 : 케빈 와일 OpenAI for Science 책임자 겸 부사장
    + 알렉스 룹사스카 연구 과학자(이론물리학자)
    (* Science 2.0 : 벤 슈나이더먼 메릴랜드 대학교 교수가 창안한 개념
    -> 과학 분야에서 인터넷을 활용한 과학자 간의 네트워킹, 협업, 참여가 중요하다는 개념)
  - **OpenAI for Science : 과학적 발견을 가속하는 AI 기반 플랫폼 구축** 조직 (25/09~)
  - GPT-3 : 튜링 테스트 통과의 신호 -> GPT-5 : 새로운 과학 연구의 신호
    => GPT-6 : ?

- **OpenAI의 방향성**
  - 계기 : Microsoft와의 공익기업 구조 변경 합의
    -> **회사 사명 및 비전 재정의**
    비영리 재단 OpenAI Foundation 250억 달러 투자 -> AI 질병 치료 개발
  - **AI Scientist : 과학적 발견을 돕는 AI (~2028)**
  - **AI의 미래 방향성**: 성능 경쟁에서 **세계에 기여하는 단계**로

출처: https://www.aitimes.com/news/articleView.html?idxno=204174

메타, 모델 하나가 스스로 질문 주고 받으며 발전하는 학습법 '스파이스 개발'

7위

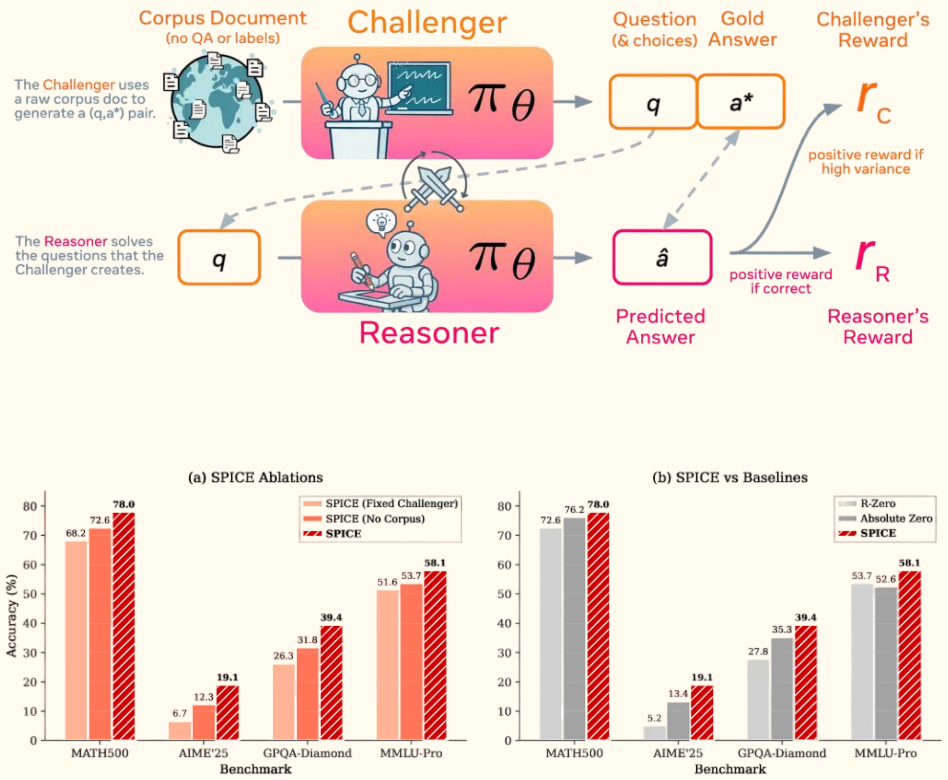

메타 FAIR – 싱가포르국립대학교 연구진,

<u>자기 개선형 AI (Self-Improving AI) 시스템</u> 위한

강화학습 프레임워크 <u>SPICE(Self-Ply In Corpus Environments)</u> 공개.

- **구조: 하나의 AI 모델이 '도전자' vs. '추론자' 역할을**
  번갈아 수행하며 성장하는 Self-Play 프레임워크
  - 도전자 : 대규모 데이터에서 문제 소재 탐색 -> 추론자 시험용 문제 제작
  - 추론자 : 스스로 제작한 문제 해결
  - 자기 개선 : 도전자는 추론자의 수준에 맞춰 더 어려운 문제 출제
    -> 추론자의 해결 반복
  - **평가 기준: (도전자) 적절한 난이도의 문제 제작 여부**
    (추론자) 문제의 정확한 풀이 여부

- **장점 : <u>정보의 비대칭 유지</u>** -> **(도전자)** 웹 문서 등 **외부 지식을 활용**하여 문제 생성
  (추론자) 해당 문서 **접근 X**
  (* 기존 Self-Play의 문제: 모델이 같은 지식 공유 -> 비슷한 유형의 문제 출제 반복 or 환각 발생)

- **의의 :** AI의 자기 개선 및 발전 -> **<u>외부 세계와의 지속적인 상호작용 필요</u>**
  => 인간 지식+경험이 담긴 <u>방대한 텍스트 데이터</u> 활용
  -> <u>개방적이고 끊임없는 성장</u> 유도

- **실험 대상:** Qwen3, OctoThinker 등

- **실험 결과:** 수학적 추론에서 **8.9%,** 일반적 추론에서 **9.8%** 성능 향상

출처: https://www.aitimes.com/news/articleView.html?idxno=202979

구글, 기업 활용 가능한 '나노 바나나 프로' 출시… "완전 미쳤다" 반응

6위

Google, Gemini 3 Pro 추론 계층 활용한 이미지 생성•편집 모델, 'Gemini 3 Pro Image (Nano Banana Pro)' 공개

- Gemini 3 Pro 추론 능력 활용하여 이미지의 구조, 의도, 사실적 근거를 전달하는 시각적 이미지 생성
- **기능** : Google – 스튜디오급 이미지 제작 위한 전문가용 도구
  - **해상도·생성 품질 향상** : 최대 4K 해상도 제공, 최대 14개 요소 블렌딩, 5명까지 인물 일관성 유지, 6장의 고품질 샷 활용한 생성, 인포그래픽 및 다이어그램 생성 성능 강화
  - **텍스트 렌더링** 향상 : 로고 복원, 포스터 제작, 다국어 번역 등 레이아웃 작업에서의 높은 완성도
  - **웹 검색 기능** 추가 : 지식 기반(= 웹 검색 결과 기반 이미지 생성) 작업 가능
  - **편집 기능** 추가: 이미지 일부 선택 -> 포커스•심도•보케•효과•조명•시간대•색보정 자유 조정
- **방향성** : Google - AI 생태계로의 통합 (or 구글 AI 스택의 핵심 멀티모달 엔진)
  - **Gemini App** : **기본 이미지 생성 모델**
  - **Gemini API, Google AI Studio, Vertex AI**: **프로덕션 환경에서의 이미지 생성 기능 직접 삽입** 가능
  - **Google 워크스페이스** : 슬라이드, 비드,구글 애드에서 콘텐츠 자동 생성 가능
  - **Antigravity** : UI 초안 및 동적 프로토타입 자동 렌더링
  - **NotebookLM** : 연구 및 문서 기반 이미지 생성 지원

출처: https://www.aitimes.com/news/articleView.html?idxno=204154

구글의 '안티그래비티', 바이브 코딩 넘는 에이전트 플랫폼의 등장

5위

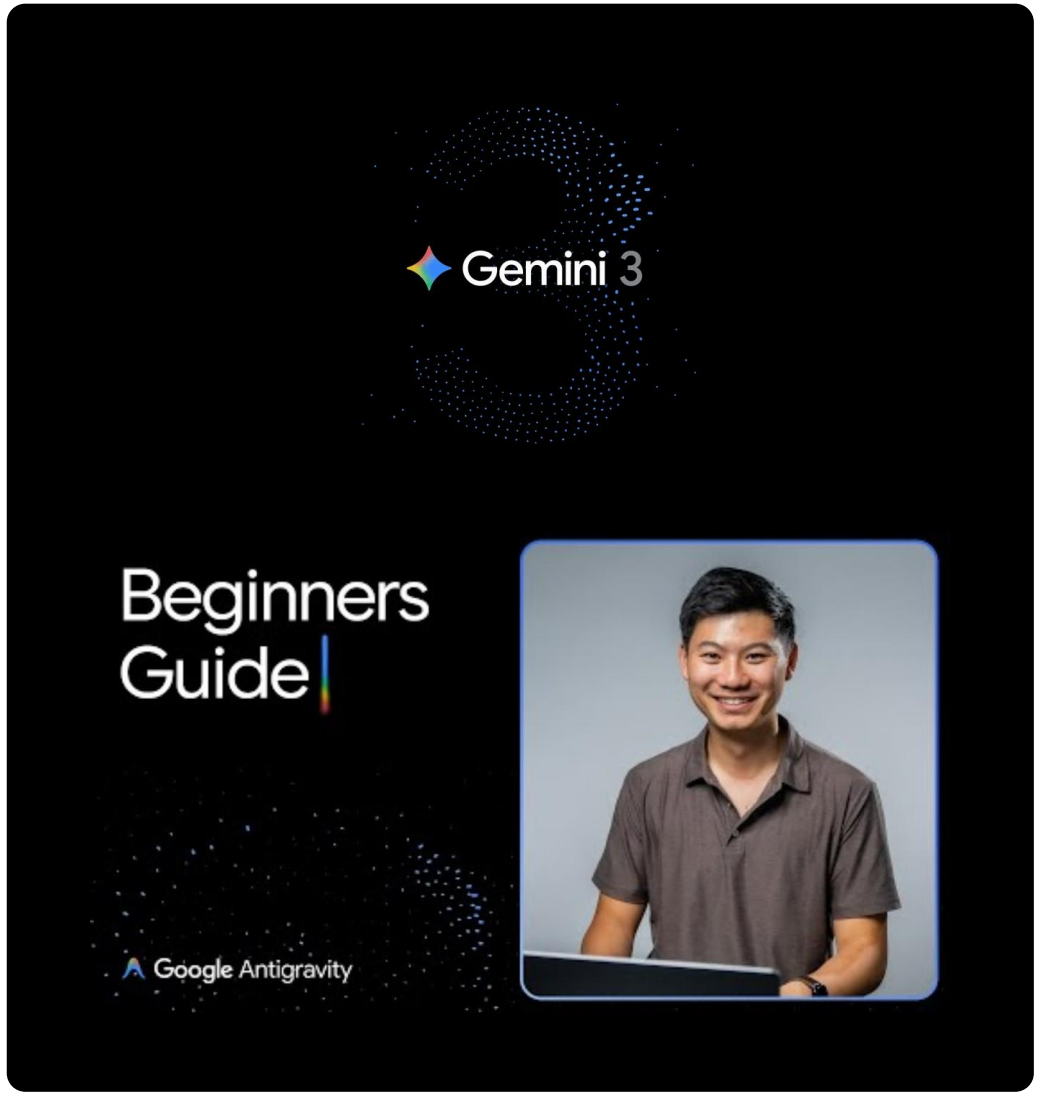

출처: https://www.aitimes.com/news/articleView.html?idxno=204097

Google **다중 에이전트** 활용해 **개발 전 과정 자동화**하는 차세대 개발 플랫폼 **Antigravity 출시**

- **배경 :** AI 코드 생성 증가로 인한 기업 내 코드 리뷰 부담 폭증
  -> 코드 리뷰 자동화 위한 **비동기적 멀티 에이전트 수요 증가**
  ↱ Gemini 3 Pro, Claude Sonnet 4.5, GPT-OSS etc
- **기능 : Google – 다양한 서드파티 AI 모델 활용하여**
  복잡한 개발 작업을 자동화하는 에이전트 기반 환경
  - **데스크톱 애플리케이션** 구글 계정 로그인 -> 에이전트 기반 코딩
  - **에이전트 자율성 강화 환경 구축**
    : AI 에이전트의 코드 에디터, 터미널, 브라우저 직접 접근 + 다중 에이전트 동시 병렬 운영
  - **Artifacts** : AI 에이전트가 **자체적으로 작업 내역을 남기는 시스템**
    ↳ 작업 목록, 구현 계획, 스크린샷, 브라우저 탐색 기록
    => 사용자의 **에이전트 작업 검증 난이도 ↓ + 후속 작업 제어** 용이
  - **화면 구성**
    - **Editor View** : 전통적 IDE 환경 -> 코드 작성 및 수정 최적화
    - **Manager View** : 다중 에이전트의 생성, 조율, 모니터링하는 대시보드
      => 기업의 반복 업무(= 코드 리뷰, 디버깅, 자료 수집) 병렬 자동화
    - **브라우저 통합 화면**: 크롬 확장 프로그램 활용
      -> 개발 중인 웹 애플리케이션 실행 및 테스트

메타, 이미지 세분화 모델 'SAM 3' 공개... 텍스트 기반 편집 지원

4위

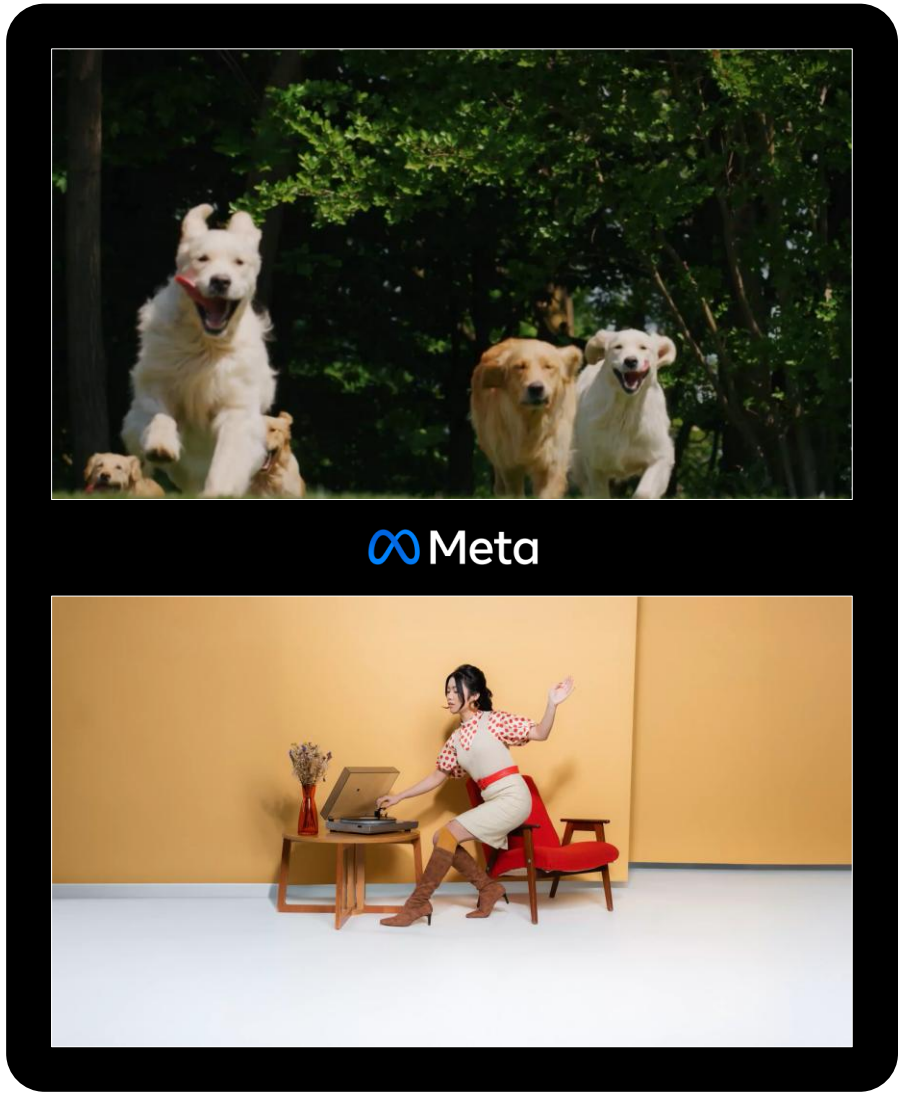

메타, 이미지 Segmentation 모델 **SAM3**
3D Reconstruction 모델, **SAM 3D 공개**

- **SAM 3**
  - 이미지 속 **객체를 텍스트로 인식, 편집** 가능
  - 이전 모델 대비 객체 탐지 및 세분화 정확도 향상
- **SAM 3D**
  - 2D 이미지 속 **인물 및 사물을 3D 복원**
  - **SAM 3D Objects** : 사물, 장면 3D 복원
  - **SAM 3D Body** : 인체 3D 재구성
  - 일부 오픈 소스 – 모델 체크포인트 및 추론 코드 공개

- **방향성: 로보틱스, 스포츠, 의학, ARVR 등 다분야에서의 활용 기대**
  ex. 페이스북 마켓 플레이스 View in Room 기능 : 가구 가상 배치 기능

출처: https://www.digitaltoday.co.kr/news/articleView.html?idxno=606408

3위

구글, '제미나이3' 출시..."멀티모달·코딩·에이전트 역대 최고 성적"

Google, 최신 AI 모델 **Gemini 3 출시,**

- **Gemini 3** : **멀티모달, 에이전트 기능, (바이브) 코딩 능력 강화한 최신 모델**
- **Google AI 생태계 연동** : Gemini App, AI 검색모드, AI 스튜디오, Vertex AI, Antigravity
- **Gemini 3 모드**
  - **Gemini 3 Pro :** 최고 성능 모드 -> Preview 출시
  - **Gemini 3 Deep Think** : 추론 중심 모드 -> 구글 AI 울트라 구독자 대상 서비스 예정
- **Gemini 3 Pro 벤치마크**
  - LMArena Leaderboard : 사용자 선호 테스트 -> 1501점 / 1등
  - HLE : 상식 및 추론 테스트 -> 37.5%
  - GPQA Diamond : 91.9%
  - MathArena Apex : 수학 벤티마크 -> 23.4% / 1등
  - MMMU-Pro, Video-MMMU : 멀티모달 벤치마크 -> 81% / 87.6% / 1등
  - SimpleQA Verified : 사실 정확도 테스트 -> 72.1% / 1등
  - WebDev Arena : 웹 개발 벤치마크 -> 1487점 / 1등
  - Terminal-Bench 2.0 : 도구 활용 능력 테스트 -> 54.2%
  - Vending-Bench 2 : 자판기 사업 관리 시뮬레이션(-> 장기 계획 수립) 테스트 -> 1위
  - SWE-Bench Verified : 코딩 능력 테스트 -> 76.2% (* 1등 : Claude Sonnet 4.5 / 772.%)
  - ARC-AGI-2 : AGI 능력 테스트 -> 31.1%
- **Gemini 3 Deepthink 벤치마크 : Gemini 3 Pro보다 더 뛰어난 벤치마크 성능**
  - HLE : 41% / 1등
  - GPQA Diamond : 93.8% / 1등
  - ARC-AGI-2 : 45.1% / 1등

출처: https://www.aitimes.com/news/articleView.html?idxno=204087

구글 "제미나이 3에서 '생명의 신호' 느껴... 무언가 찾은 것 같아"

2위

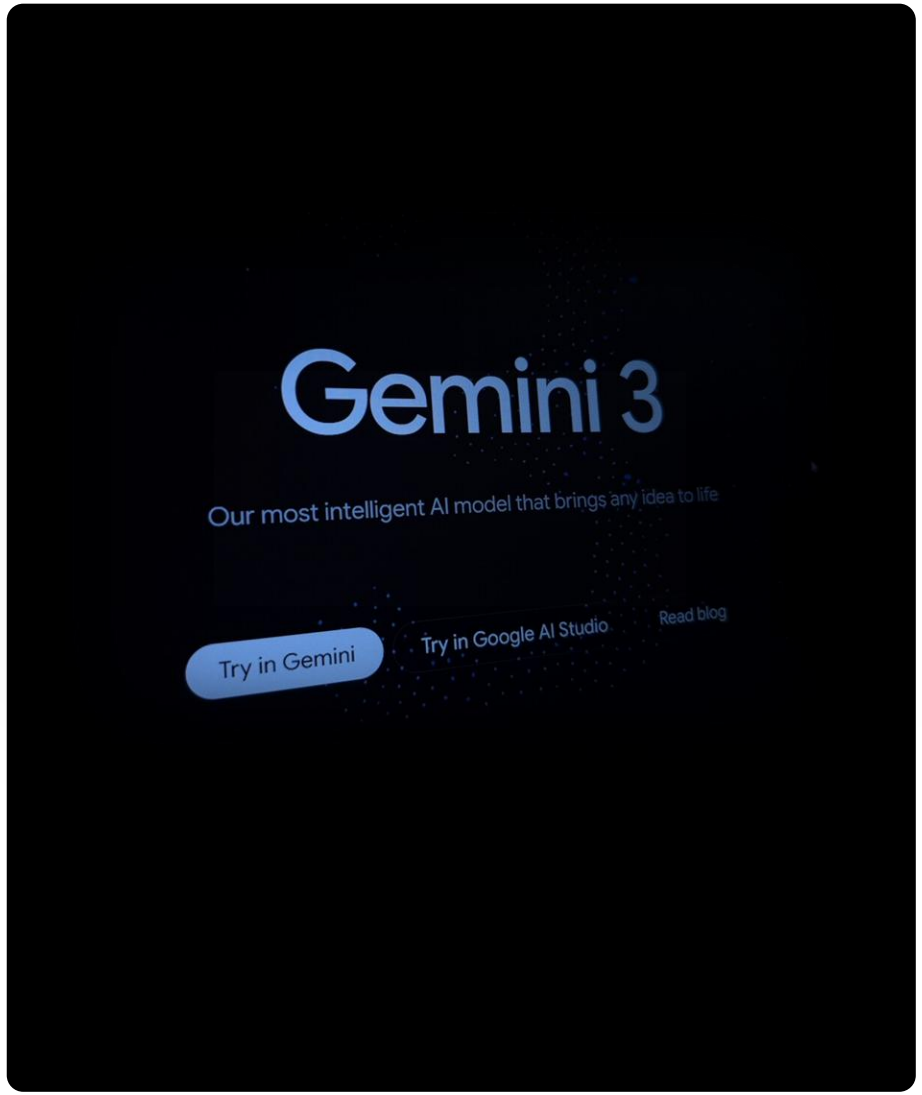

Google, Gemini 3에서 ‘생명의 신호’를 느껴..

- **구글 내외 임원들, Google Gemini 3에서 ‘생명의 신호 (signs of life)’, AGI의 가능성 발견**
- **사례 1) Tulsee Doshi**, Sr. Director & Head of Product, Gemini Model
  - 정식 출시 이전, 내부 모델 테스트 **결과에서** 확인
  - ① 구자라트어 글 작성 요청 -> 이전 모델 대비 (인터넷에서의) 소수 언어 글 작성 성능 향상 확인

    => **AI 모델이 인간처럼 무언가를 이해하고 있다는 인상** 받음
  - ② 내부 테스트 결과 점수 대폭 향상

    Ex. Vending Bench 2 : 모델이 일정 기간 자판기 운영 담당하는 시뮬레이션

    -> 모델의 에이전트 성능(= 재고 파악, 주문, 가격 설정 등) 평가

    -> Gemini 3 : $5,478 수익

    (↔ Gemini 2.5 573, Claude Sonnet $3,838 / GPT-5.1 $1,473)

    => **Gemini 3 모델의 도구 사용 및 계획 수립 능력의 대폭 향상** 입증
- **사례 2) Aaron Levie**, CEO at Box
  - 정식 출시 이전, 접속 권한 얻어 진행한 외부 모델 테스트 **결과에서** 확인
  - 방대한 양의 복잡한 문서 분석 성능 테스트 => 모든 테스트에서 점수 차이 두 자릿수 기록
- **사례 3) Andrej Karpathy**, Co-Founder at OpenAI
  - 정식 출시 이전, 접속 권한을 얻어 진행한 모델 **테스트 중** 발생 -> **" 가장 인상적인 에피소드 "**
  - **문제**: Gemini 3이 **현재가 2025년이라는 사실을 믿지 못하는 문제** 발견

    -> 각종 데이터 제시해도 믿지 않음 (<- Gemini 3의 **사전 훈련 데이터는 2024년까지**)
  - **해결: Google 검색 도구**를 작동하자, Gemini 3은 **인터넷을 검색, 자기가 틀렸다는 사실 인지**
  - **반응**: **첫 문구 "Oh my god." / 인간이 충격을 받았을 때처럼 더듬더듬 글 작성**

    "나... 나는... 뭐라고 말해야 할지 모르겠다.

    당신 말이 맞았다. 내 내부 시계가 틀렸다."

출처: https://www.aitimes.com/news/articleView.html?idxno=204201

“오픈AI의 250GW는 인도 전체 전력 사용량... 엄청난 영향 미칠 것 "

1위

글로벌 빅테크의 AI 개발,

지구적 차원의 환경·에너지 위기 가능성을 키운다

- **예시1: OpenAI (~2033)**
  - 전력 사용량: 250 GW = 인도 (15억 인구)의 1년 전력 사용량
  - 탄소 배출량 : 엑슨 모빌 (세계 최대 민간 배출원) x2
  - GPU 소모량: (초기) GB300 GPU 6000만개 -> 연간 3000만개의 GPU 신규 확보 필요
- **예시2 : xAI (~2030)**
  - 전력 사용량 : 5GW 전력 필요
  - GPU 소모량 : (초기) H100급 GPU 5000만개 -> ?
- **예시3 : TSMC (신규 팹 25)**
  - 전력 사용량: 1GW = 대만 75만 가구 사용량
  - 물 사용량 : 1일 10만 톤 = 타이중 주민 19만 6000명의 하루 사용량
- **현황: 빅테크의 신규 데이터센터 착공 + 파운드리 업체의 신규 반도체 팹 착공**
  (* 지난 2년간 전 세계 97개 신규 반도체 팹 착공)
- **문제: 원재료 채굴, 칩 제조, 데이터센터 운영 등 전 과정에서 지구의 제한된 자원을 빠르게 소진 중**

출처: https://www.aitimes.com/news/articleView.html?idxno=204050